

Projektvorschlag: Automatisierte Extraktion von Daten aus Todesanzeigen

Projektziel

Entwicklung einer automatisierten Lösung zur Extraktion strukturierter Informationen aus ca. 87.000 Bilddateien von Todesanzeigen sowie deren Überführung in eine standardisierte Excel-Datei.

Die Hauptziele sind:

- Minimierung manueller Dateneingabe
- Hohe Extraktionsgenauigkeit
- Kostenbewusste Verarbeitung großer Datenmengen
- Unterstützung verschiedener Zeitungsquellen und Layouts
- Verarbeitung sowohl digitaler Anzeigen als auch fotografierte Zeitungsausschnitte

Datensatzübersicht

Aktueller Datenbestand:

Kategorie	Anzahl Bilder
Saubere digitale Bilder	ca. 57.000
Fotografierte Zeitungsausschnitte	ca. 14.000
Gemischte / unbekannte Qualität	ca. 16.000
Gesamt	ca. 87.000

Der Großteil der Bilder stammt aus bestimmten Zeitungsquellen, wobei die Bilder innerhalb eines Ordners meist ähnliche Layouts und Qualitätsmerkmale aufweisen.

Dadurch kann für jede Quelle ein optimierter Verarbeitungsweg gewählt werden, anstatt eine einzige Methode auf den gesamten Datensatz anzuwenden.

Vorgehensweise

Quellenbasierte Verarbeitung

Die Verarbeitung erfolgt ordnerweise nach Zeitungsquelle.

Vorteile:

- Konsistente Bildqualität innerhalb einer Quelle
- Ähnliche Layouts und Schriftarten
- Geringere API-Kosten
- Höhere Extraktionsgenauigkeit
- Einfachere Fehleranalyse

Für jede Quelle wird zunächst eine Stichprobe analysiert, anschließend wird die geeignetste Verarbeitungsmethode für den gesamten Ordner ausgewählt.

Verarbeitungspipeline

Phase 1: Saubere digitale Bilder

Diese Kategorie umfasst den größten Teil des Datensatzes.

Pipeline:

Bild
↓
OCR
↓
Textextraktion
↓
LLM-basierte Strukturierung
↓
JSON-Ausgabe
↓
Excel-Export

Zu extrahierende Felder:

- Geschlecht
- Name
- Vorname
- Foto (ja/nein)

- Geburtsdatum
- Sterbedatum
- Geburtsname
- Titel
- gennant
- Geburtsort
- Sterbeort
- Wohnort
- Ort (Anzeige- Berufs- Lebensort)
- weitere Orte
- Beruf
- Bemerkungen
- Quelle
- Dateiname
- Zusätzliche Hinweise

Erwartete Genauigkeit

95–99 %

Erwartete Kosten

Niedrig

Phase 2: Untersuchung der Zeitungsfotos

Fotografierte Zeitungsausschnitte stellen die größte technische Herausforderung dar.

Typische Probleme:

- Perspektivische Verzerrungen
- Unschärfe Aufnahmen
- Zusätzliche Bildbereiche außerhalb der Anzeige
- Mehrere Anzeigen auf einem Foto
- Unterschiedliche Beleuchtung

Vor der Massenverarbeitung wird daher ein eigener Evaluierungs- und Forschungsabschnitt durchgeführt.

Experimentelle Untersuchung

Stichprobe:

- 100–300 Zeitungsbilder

Verglichene Ansätze:

Variante A

Bild
↓
OpenCV-Vorverarbeitung
↓
Automatisches Zuschneiden
↓
OCR
↓
LLM-Extraktion

Variante B

Bild
↓
Vision-Modell
↓
Strukturierte Extraktion

Variante C

Bild
↓
OpenCV-Zuschnitt
↓
Vision-Modell
↓
Strukturierte Extraktion

Bewertungskriterien:

- Extraktionsgenauigkeit
- Verarbeitungsgeschwindigkeit
- Kosten pro Bild
- Fehlerrate

Anschließend wird die wirtschaftlichste und zuverlässigste Methode ausgewählt.

Projektzeitplan

Juni

Meilenstein 1 – Projektaufbau

Ergebnisse:

- Analyse des Datenbestands
- Kategorisierung der Quellen
- Definition des Zieldatenmodells
- OCR-Evaluierung

Meilenstein 2 – Prototyp für digitale Bilder

Ergebnisse:

- OCR-Pipeline
- LLM-Extraktionspipeline
- Excel-Export
- Erste Qualitätsmessungen

Ziel:

Verarbeitung der ersten sauberen Bildquellen.

Juli

Meilenstein 3 – Verarbeitung der sauberen Bildquellen

Ergebnisse:

- Produktionsreife Pipeline
- Ordnerweise Verarbeitung
- Qualitätskontrolle und Fehleranalyse

Ziel:

Abschluss des Großteils der digitalen Bildbestände.

Juli – August

Meilenstein 4 – Untersuchung der Zeitungsbilder

Ergebnisse:

- OpenCV-Prototyp
- Vergleich verschiedener Vision-Modelle
- Kosten- und Qualitätsanalyse

Ziel:

Auswahl der optimalen Methode für Zeitungsbilder.

August

Meilenstein 5 – Verarbeitung der Zeitungsbilder

Ergebnisse:

- Massenverarbeitung der Zeitungsbestände
- Qualitätssicherung
- Konsolidierung aller Ergebnisse

Meilenstein 6 – Projektabschluss

Ergebnisse:

- Finaler Excel-Datensatz
 - Dokumentation der Verarbeitungslogik
 - Abschlussbericht
-

Technologie-Stack

Programmiersprache

- Python

Bildverarbeitung

- OpenCV
- Pillow
- NumPy

Datenverarbeitung

- Pandas
- OpenPyXL

OCR

Primär:

- Google Document AI OCR

Alternativ:

- Tesseract OCR

KI-Modelle

Primär:

- Gemini Flash Lite
- Gemini Flash

Fallback für schwierige Fälle:

- OpenAI Vision-Modelle
- Claude Sonnet

Diese Modelle werden nur bei problematischen Bildern eingesetzt.

Qualitätssicherung

Für jeden Datensatz wird eine automatische Vertrauensbewertung (Confidence Score) berechnet.

Beispiele:

- Fehlendes Geburtsdatum
- Mehrdeutige Namen
- Niedrige OCR-Qualität
- Widersprüchliche Angaben

Solche Datensätze werden automatisch markiert und können gezielt überprüft werden.

Ziel:

Weniger als 1 % manueller Nachbearbeitungsaufwand.

Budgetschätzung

Forschungs- und Evaluierungsphase

Umfasst:

- OCR-Vergleich
- Vision-Modell-Vergleich
- Untersuchung der Zeitungsbilder

Geschätzte API-Kosten:

20 € – 100 €

Produktive Verarbeitung

Best Case

Annahmen:

- Großteil der Bilder kann per OCR verarbeitet werden
- Geringer Einsatz von Vision-Modellen
- Niedrige Fehlerrate

Geschätzte Kosten:

100 € – 300 €

Erwarteter Fall

Annahmen:

- OCR für digitale Bilder
- Vision-Fallback für schwierige Fälle
- Einsatz der optimierten Zeitungspipeline

Geschätzte Kosten:

300 € – 800 €

Worst Case

Annahmen:

- Hoher Anteil schwieriger Zeitungsbilder
- Zusätzliche Verifikationsschritte notwendig

Geschätzte Kosten:

1.000 € – 3.000 €

Dieses Szenario wird derzeit als eher unwahrscheinlich eingeschätzt.

Einflussfaktoren auf Kosten und Zeitaufwand

Bildqualität

Schlechtere Bildqualität führt zu:

- Höheren OCR-Fehlerraten
- Mehr Vision-Modell-Aufrufen
- Mehr manueller Nachbearbeitung

Layoutvielfalt

Stark abweichende Anzeigenlayouts können zusätzliche Anpassungen erfordern.

Umfang der gewünschten Datenfelder

Je mehr Felder extrahiert werden sollen, desto komplexer wird die Verarbeitung.

Qualitätsanforderungen

Eine Zielgenauigkeit von über 99 % kann zusätzliche Verifikationsschritte erforderlich machen und damit Kosten und Laufzeit erhöhen.

Erwartetes Ergebnis

Durch die quellenbasierte Verarbeitung und die Priorisierung kostengünstiger OCR-Verfahren für saubere digitale Bilder kann ein sehr großer Teil des Datensatzes effizient und präzise verarbeitet werden.

Aufwendigere Vision-Modelle werden gezielt nur dort eingesetzt, wo klassische OCR-Verfahren an ihre Grenzen stoßen.

Dadurch entsteht eine skalierbare, kosteneffiziente und qualitativ hochwertige Lösung zur automatisierten Erfassung historischer Todesanzeigen.